

PROJET GC-MS

Groupe 14

Rendu n°1

Date : 05/10/2026

Membres du groupe :

Steve Landry OUOAM (chef de groupe)

Ludovic TUEAM

Radia GHILAS

Harald MAFORIAN

Ismaila DIEE

Données nécessaires, structure exploitable et visualisations du projet GC-MS.

1. Quelles données devons-nous extraire ?

Notre objectif est de déterminer la concentration des 16 hydrocarbures aromatiques polycycliques (HAP) ciblés par la méthode, dans une solution analysée par GC-MS. Nous devons relier les signaux mesurés à des molécules connues, puis convertir leur réponse en concentration grâce à une calibration vérifiée. [1, 2]

Les informations indispensables

Données nécessaires	Utilité	Source à exploiter
Liste des 16 HAP, ions quantifiants et qualifiants	Savoir quelles molécules et quels canaux rechercher.	metadata.xlsx
Association de chaque HAP à son étalon interne (ISTD)	Corriger les variations de réponse par un ratio d'aires.	Feuille compound_deuterated
Séries temps / intensité pour chaque ion utile	Détecter les pics et calculer leurs aires, dans les GAM, SF et futurs échantillons.	Données MS des dossiers .D, à convertir
Identité, type, date, niveau et facteur de dilution	Relier chaque signal à la bonne acquisition et corriger la concentration.	sample_info.xml et journaux TSV
Concentrations connues des huit GAM	Établir la relation entre réponse normalisée et concentration.	Document GAM + rapport de calibration
Concentration nominale des SF	Vérifier la justesse du retour-calcul sur un contrôle connu.	Cours du 5 octobre : 1 ppm ; tolérance de conformité à préciser
Ordre des pics et cas particuliers	Distinguer des molécules qui partagent les mêmes ions.	Métadonnées et méthode analytique
Tolérances et règles de traitement	Décider si l'identification et la quantification sont acceptables.	Paramètres métier à définir ou confirmer

Les repères à calculer à partir de ces données

Sur GAM-6, nous construirons les temps de rétention de référence, les bornes d'intégration et le ratio qualifiant/quantifiant attendu. Puis nous calculerons les aires des pics, les ratios composé/ISTD et les coefficients de calibration. Ces informations sont des résultats du traitement, pas toutes des colonnes déjà disponibles dans le ZIP. [1]

Un ion isolé ne suffit pas à identifier une molécule : nous devons croiser les deux canaux, leur temps de rétention et l'ordre des pics. Une concentration exploitable exige ensuite une calibration et un contrôle SF satisfaisants.

2. Comment comprenons-nous la structure ?

Nous distinguons la méthode analytique, les acquisitions instrumentales et les résultats du traitement. La méthode indique quoi chercher. Les acquisitions enregistrent les signaux. Le traitement transforme ces signaux en concentrations traçables.

Les rôles des échantillons

Échantillon	Rôle	Présence dans 20251103.zip
GAM-6, parmi les GAM	Construire les repères de référence.	Un point à 1 ppm, inclus dans les 8 GAM
GAM-1 à GAM-8	Calibrer chaque composé à partir de concentrations connues.	8 acquisitions : 0,025 ; 0,05 ; 0,1 ; 0,2 ; 0,5 ; 1 ; 2 ; 5 ppm
SF	Vérifier la calibration sur une solution de contrôle.	4 acquisitions ; nominal annoncé en cours : 1 ppm
Hexane	Acquisitions de solvant, rôle précis de blanc à confirmer.	6 acquisitions
BLPC	Appliquer ultérieurement la méthode à des échantillons de terrain.	28 acquisitions, dont 3 avec suffixe d20

Le périmètre demandé par le cahier des charges est la référence, la calibration GAM et le contrôle SF. Les BLPC permettent de comprendre l'application finale, mais leur quantification n'est pas exigée dans ce périmètre. La référence est une acquisition GAM choisie, pas un neuvième étalon indépendant. [1, 3]

Ce que contient réellement le ZIP brut

Le batch 20251103 regroupe 46 dossiers .D. Chaque dossier contient notamment des données MS natives (data.ms et fichiers BIN), des XML de métadonnées, la méthode instrumentale et un chromatogramme global tic_front.csv / tic_front.tsv. QuantReports contient 61 CSV de résultats et 8 PDF. QuantResults contient le batch binaire du logiciel. [3]

Les TIC globalisent le signal et ne fournissent pas séparément les intensités des ions 128 et 127, par exemple. Les CSV de résultats contiennent des valeurs déjà calculées par le laboratoire. Ils serviront à comparer notre futur traitement, mais ne remplacent pas les séries brutes par ion nécessaires pour automatiser l'intégration.

Le cahier des charges décrit un jeu préparé, cache_gam_sf.zip, avec cinq batchs et des fichiers mz_XXX.csv. Le ZIP exploré est un seul batch natif, plus large en types d'échantillons. Nous devons donc obtenir le jeu préparé ou convertir les canaux ioniques utiles de cette archive. [1, 3]

3. Une structure de données exploitable

Nous proposons de conserver les fichiers natifs intacts et de produire des tables séparées, reliées par batch_id, sample_id et compound_id. Les identifiants doivent distinguer chaque acquisition, notamment les réinjections diluées.

Un modèle de données simple et traçable

Table proposée	Informations à conserver
samples.csv	batch_id, sample_id, sample_type, gam_level, concentration_known_ppm, dilution_factor, acquisition_datetime, source_path
compounds.csv	compound_id, nom, type, quantifier_mz, qualifier_mz, istd_id, ordre des pics, double_peak, median_despike, domaine d'application
signals.parquet ou signals.csv	batch_id, sample_id, mz, time_min, intensity, unité du signal, source_path. Une ligne = une mesure d'un ion à un instant.
references.csv	batch_id, compound_id, reference_sample_id, canal, rt_ref_min, t_start_min, t_end_min, ratio_qual_quant_ref
peaks.parquet ou peaks.csv	batch_id, sample_id, compound_id, aires quantifiante / qualifiante / ISTD, temps et bornes d'intégration, ratios et anomalies
calibrations.csv	batch_id, compound_id, a, b, c, R ² , pondération, niveaux utilisés, domaine de calibration, statut
results.csv	batch_id, sample_id, compound_id, concentration_injected_ppm, dilution_factor, concentration_final_ppm, statut et raisons du contrôle

Une première conversion compatible avec le sujet

Une organisation batch / échantillon / mz_XXX.csv est également adaptée. Chaque fichier contiendrait exactement les colonnes time_min et intensity, avec les unités documentées. Un multiplier.txt ou une ligne de samples.csv porterait le facteur de dilution. Ces exports peuvent ensuite être regroupés dans la table signals. [1]

Exemple de chemin proposé : prepared/20251103/GAM-6/mz_128.csv. Il s'agit d'un format cible : ce fichier n'existe pas dans le ZIP brut. Les signaux extraits doivent correspondre aux ions acquis, ici notamment 128,1 et 127,1. Nous documenterons la correspondance avec les valeurs nominales 128 et 127 du classeur. [2, 3]

Le lecteur doit préserver les temps réellement enregistrés, car le pas temporel varie. Un canal SIM n'est mesuré que dans sa fenêtre d'acquisition : une valeur non acquise ne doit pas être remplacée automatiquement par zéro. Les noms de composés et les versions des exports doivent aussi être harmonisés et conservés.

4. Du signal à la concentration

La chaîne dépend de trois briques, dans cet ordre : construire la référence, calibrer avec les GAM, puis vérifier avec les SF. La mesure d'un échantillon inconnu vient ensuite. [1]

Étape	Traitement prévu	Résultat
1. Référence GAM-6	Repérer chaque composé sur ses deux ions. Déterminer l'apex et les bornes du pic.	Temps, fenêtres et ratio ionique de référence
2. Intégration	Rechercher les pics voisins de la référence dans chaque GAM. Intégrer le signal selon une règle de ligne de base documentée.	Aires quantifiante, qualifiante et ISTD
3. Normalisation	Diviser l'aire quantifiante du composé par l'aire de son ISTD associé.	Réponse normalisée r
4. Calibration	Ajuster un polynôme de degré 2 sur les huit couples concentration connue / réponse. Examiner R^2 et résidus.	Une courbe par batch et par composé
5. Contrôle SF	Intégrer les SF, inverser la calibration et comparer la concentration obtenue au nominal.	Conformité selon une tolérance justifiée
6. Application	Appliquer la calibration vérifiée à une solution inconnue et tenir compte de sa dilution.	Concentration finale et statut de validité

Deux ratios différents, pour deux besoins

Identification : $q = \text{aire_qualifiante} / \text{aire_quantifiante}$. Nous comparons q au ratio de référence pour vérifier la cohérence du pic.

Quantification : $r = \text{aire_quantifiante_du_composé} / \text{aire_quantifiante_de_son_ISTD}$. C'est r que nous relient à la concentration C : $r = a \times C^2 + b \times C + c$.

Pour un nouvel échantillon, nous résolvons $a \times C^2 + b \times C + (c - r) = 0$. Nous retenons une solution positive, cohérente avec la branche et le domaine validés de la calibration. Une solution ambiguë, hors domaine ou non réelle doit produire un statut explicite, pas une concentration arbitraire.

La correction attendue est **C_finale = C_solution_injectée × facteur_de_dilution**, selon la définition validée du facteur. Nous conservons les deux concentrations. Un résultat déjà exporté et corrigé ne doit pas recevoir une seconde fois le multiplicateur. La conversion en concentration dans un sol ou un enrobé demanderait aussi les paramètres de préparation et les unités correspondantes.

5. Rendu attendu et informations à confirmer

Le résultat final doit répondre, pour chaque échantillon et chaque HAP ciblé : quel composé avons-nous recherché, son identification est-elle cohérente, quelle concentration estimons-nous et pouvons-nous utiliser cette valeur ?

Une ligne de résultat par échantillon et par composé

Information restituée	Contenu attendu
Identité et provenance	Batch, acquisition, composé, fichiers sources et version du traitement
Identification	Temps de rétention, deux ions, ratio ionique, anomalies éventuelles
Mesure	Aires intégrées et réponse normalisée composé/ISTD
Concentration	Valeur avant correction, facteur de dilution, valeur finale et unité
Validité	Calibration utilisée, contrôle SF, statut exploitable / à vérifier / non quantifiable, avec motif

Les points à préciser avant le calcul complet

Nous devons confirmer le moyen d'extraire les canaux MS, la tolérance de conformité et les règles d'intégration. Il faut aussi préciser le traitement des pics partagés, du double pic et du paramètre median_despike. Les notes indiquent des tolérances de ratio et de rétention de $\pm 23\%$ et $\pm 0,2\%$, mais leurs conventions doivent être confirmées. [1, 2, 4]

Les rapports MassHunter montrent une calibration quadratique pondérée en $1/x$ pour les HAP. Cette information devra être prise en compte si nous cherchons à reproduire ces résultats. Un R^2 élevé ne suffit pas : les SF vérifient la justesse, et les contrôles d'identification vérifient la cohérence des molécules. [1, 3]

Une absence de pic exploitable doit rester distincte d'une concentration nulle ou d'une absence certaine de la molécule. Les seuils de détection et de quantification, s'ils sont requis, doivent être fournis ou justifiés.

Notre compréhension à ce stade

Nous avons identifié les molécules ciblées, leurs ions, leurs étalons internes, les huit concentrations GAM et les métadonnées d'acquisition. Le travail restant consiste à extraire les signaux par ion, calculer les références et les aires, construire les calibrations puis valider les contrôles. Ce rendu présente les données nécessaires et notre organisation proposée ; il ne prétend pas avoir déjà recalculé les concentrations.

Sources utilisées

[1] projet_optimisation_operationnel.pdf, sections 2 à 5, pages 2 à 5. [2] metadata.xlsx, feuilles compound_information et compound_deuterated. [3] 20251103.zip : données natives, sample_info.xml, journaux de séquence, acqmeth.txt et QuantReports. [4] concentration point de GAM.docx, Notes sujet GCMS à automatiser.md et Explication GCMS.excalidraw. Les constats sur l'archive proviennent de l'exploration réalisée le 5 octobre 2026.

Annexe. Les 16 molécules ciblées

Les valeurs ci-dessous reproduisent la méthode fournie dans metadata.xlsx. Elles indiquent les m/z nominaux. Les acquisitions instrumentales comportent des valeurs décimales correspondantes. [2, 3]

Composé	m/z quant.	m/z qual.	Étalon interne associé
Naphtalene	128	127	Naphtalene-D8
Acenaphtylene	152	153	Naphtalene-D8
Acenaphtene	153	154	Acenaphtene-D10
Fluorene	166	165	Acenaphtene-D10
Phenanthrene	178	176	Phenanthrene-D10
Anthracene	178	176	Phenanthrene-D10
Fluoranthene	202	101	Phenanthrene-D10
Pyrene	202	101	Phenanthrene-D10
Benzo(a)anthracene	228	226	Phenanthrene-D10
Chrysene	228	226	Chrysene-D12
Benzo(b)fluoranthene	252	253	Chrysene-D12
Benzo(k)fluoranthene	252	253	Chrysene-D12
Benzo(a)pyrene	252	253	Chrysene-D12
Dibenz(a,h)anthracene	278	279	Chrysene-D12
Indeno(1,2,3-cd)pyrene	276	277	Chrysene-D12
Benzo(g,h,i)perylene	276	277	Chrysene-D12

Les points particuliers de la méthode

Phenanthrene et Anthracene partagent 178/176 ; Fluoranthene et Pyrene partagent 202/101 ; Benzo(a)anthracene et Chrysene partagent 228/226. Plusieurs composés partagent 252/253 ou 276/277. Le temps de rétention, l'ordre et les fenêtres d'intégration restent nécessaires pour les distinguer.


Benzo(b)fluoranthene et Benzo(k)fluoranthene portent un ordre de coélution 0 puis 1. Dibenz(a,h)anthracene comporte double_peak = True. Indeno(1,2,3-cd)pyrene comporte median_despike = 1. Nous devons conserver ces paramètres dans la table de méthode et définir leur effet dans le traitement.

Les quatre ISTD sont Naphtalene-D8 (136/135), Acenaphtene-D10 (164/162), Phenanthrene-D10 (188/187) et Chrysene-D12 (240/236). Le classeur décrit aussi deux surrogats actifs pour GAM/BLPC et un surrogat inutilisé ; leur rôle de suivi doit être distingué de la normalisation par les ISTD.

6. Visualisations du batch


Nous comptons les acquisitions pour comprendre le rôle des données. Les GAM construisent la calibration ; les SF la contrôlent ; les BLPC correspondent à l'application aux échantillons.

Répartition des 46 acquisitions du lot 20251103



Le batch contient 8 GAM, 4 SF, 6 acquisitions d'hexane et 28 BLPC. Nous comptons des acquisitions : certaines correspondent à des réanalyses diluées.


Les huit concentrations connues de la gamme



Ce graphique montre les concentrations connues des GAM. Ce n'est pas encore notre courbe d'étalonnage : il manque les réponses calculées à partir des aires des pics. GAM-6 vaut 1 ppm.

. Lecture des chromatogrammes TIC

Le TIC est le signal global enregistré en fonction du temps. Les quatre courbes ci-dessous sont divisées par leur propre maximum pour comparer leur forme.




Ce que nous avons compris

Les pics indiquent des variations du signal, mais ne suffisent pas à identifier les HAP. Les hauteurs normalisées ne permettent pas de comparer directement les concentrations entre les quatre acquisitions.

Pour calculer les concentrations, nous devons extraire les signaux de chaque ion, repérer les pics, intégrer leurs aires et utiliser les étalons internes et la calibration.

. Référence de contrôle pour la suite

Les valeurs ci-dessous sont déjà publiées dans les rapports MassHunter. Elles serviront à comparer notre futur traitement ; nous ne les avons pas recalculées à partir des signaux par ion.



Les RSE publiés vont de 1,1 % à 6,9 %. Les R^2 sont compris entre environ 0,999039 et 0,999975. Nous ne définissons pas ici de seuil de conformité du RSE.

Notre travail restant

Extraire les ions, construire les repères sur GAM-6, intégrer les pics, ajuster les calibrations et vérifier les SF à 1 ppm avant d'appliquer le traitement aux échantillons inconnus.

Le notebook joint détaille notre compréhension et explique le code ligne par ligne. Les photos du cours du 5 octobre complètent les documents initiaux pour le nominal SF et les exemples d'intégration.